

特 別 研 究 報 告

題目

対照学習と強化学習によるオノマトペの歩容スタイル付与

指導教員

吉川 雄一郎 教授

堀井 隆斗 准教授

報告者

佐々木 條太 (09C23707)

令和 7 年 2 月 5 日

大阪大学基礎工学部システム科学科知能システム学コース

概要

目次

第 1 章	序論	1
1.1	背景と目的	1
1.2	音楽生成における課題：可視化の壁と時間性	2
1.3	本研究のアプローチ	4
1.4	本論文の構成	4
第 2 章	理論・関連研究	6
2.1	創造的パートナーシップ	6
2.2	音楽生成における制御と演奏レンダリング	9
第 3 章	提案手法	13
3.1	システム概要	13
3.2	対話システムとアルゴリズム	13
3.3	UI の構築	14
第 4 章	実験	18
4.1	RenderBox の訓練	18
4.2	被験者実験	20
第 5 章	結果	24
5.1	RenderBox の評価	24
5.2	提案システムの評価	26
第 6 章	考察	27
6.1	RenderBox の性能について	27
6.2	提案手法について	27

第 7 章 結論	28
謝辭	29
参考文献	30
付録	30

図目次

2.1	ICPL のシステム構成図 ([?] より引用)	8
2.2	ICPL を作曲 AI に応用したシステム構成図 ([?] より引用)	9
2.3	ICPL で人の好みを最大化する音楽の探索イメージ ([?] より引用) . . .	10
2.4	RenderBox のアーキテクチャ概要	12
3.1	提案システム構成図	14
5.1	RenderBox の性能評価：CLAP score	25
5.2	RenderBox の性能評価：pitch の正確さ	25
5.3	RenderBox の性能評価：tempo のずれ	26

表目次

3.1	時系列順の LLM プロンプト構成と Role の定義	17
4.1	カリキュラム学習の各ステージで使⽤したデータセット [?]	19
4.2	被験者実験で使⽤したアンケート項目一覧	23
5.1	RenderBox [?] との性能比較（括弧内は文献値）	24

第 1 章

序論

1.1 背景と目的

1.1.1 創造的活動における AI のパラダイムシフト

近年、深層学習技術の飛躍的な進歩、とりわけ大規模言語モデル（LLM）や拡散モデルに代表される生成 AI（Generative AI）の登場は、人工知能の役割を根本から変えつつある。従来の AI は、認識、分類、最適化といった定型的なタスクを効率化するための「自動化ツール」としての側面が強かった。しかし、現在の生成 AI は、文章執筆、画像生成、楽曲制作など、かつては人間の独壇場であった創造的領域（Creativity）において、人間と同等あるいはそれ以上の品質で成果物を生成する能力を獲得している。

この技術的進歩は、人間と AI の関係性において新たなパラダイムシフトをもたらしている。すなわち、人間が抱く明確な完成イメージを効率的に具現化する「道具」としての役割を超え、人間が想起し得なかったアイデアを提示し、創造性を拡張する「パートナー」としての可能性である。

1.1.2 一方的な命令から双方向の共創へ

しかしながら、現状の多くの生成 AI システムにおけるインタラクションは、依然として人間が一方的に命令（プロンプト）を与え、AI がそれを出力するという「主従関係（Master-Slave）」の枠組みに留まっている。この一方通行の構造には、創造的パートナーシップを築く上で 2 つの本質的な課題が存在する。

第一に、「**意図の言語化**」の壁である。創造的活動の初期段階において、人のアイデアは往々にして曖昧であり、言語化できない暗黙的なイメージを含んでいる。一方的な命令

形式では、ユーザーが自身の意図を完璧に言語化できなければ、望む結果を得ることができない。

第二に、「フィードバック」の硬直性である。AI の出力がユーザーの意図と乖離した場合、プロンプトを書き直して再生成するという不連続な作業が必要となり、これが創造的なフロー状態（Flow State）を阻害する要因となる。

真に創造的な共創を実現するためには、AI が人間の命令を機械的に処理するだけでなく、互いの意図を理解し、刺激し合う「動的な相互作用（Dynamic Interaction）」が必要不可欠である。本研究では、この動的な相互作用を以下の 3 つの要素を包含するプロセスと定義し、その実現を目指す。

1. **人間の内部状態の変容**: AI との対話や生成された結果を通じて、ユーザー自身の感じ方や思考、あるいは当初抱いていた目標イメージそのものが変容・深化すること。
2. **相互創発性**: ユーザーと AI、互いのアイデアが刺激となり、一人（あるいは AI 単体）では到達し得ない新たな創造や表現が生まれること。
3. **文脈の共有と記憶**: その場限りの一時的な応答ではなく、過去の対話履歴や修正の経緯（コンテキスト）を踏まえ、互いの意図を深く理解した上での継続的なやり取りが行われること。

1.2 音楽生成における課題：可視化の壁と時間性

人と AI が共創を行う際、対象となるドメイン（創作分野）の特性によって、コミュニケーションの様相は大きく異なる。本研究では、数ある創作活動の中でも「音楽（演奏表現）」を対象とする。その理由は、画像生成やテキスト生成と比較した際、音楽が持つ「不可視性」と「時間依存性」という特性が、AI との意思疎通において特有かつ高度な課題を提起するためである。

1.2.1 可視性と一覽性の欠如

画像生成の領域において、AI の出力結果は常に「可視化」された状態で提示される。ユーザーは生成された画像を視覚的に捉え、全体像（ゲシュタルト）を瞬時に把握することが可能である。また、修正プロセスにおいても、「右上の雲を消して」や「背景の色を明るくして」といった具合に、空間的な位置を指差すように具体的な指示を出すことができる。これは、視覚情報が持つ「一覽性（Synoptic view）」による恩恵である。

対照的に、音楽は本質的に「不可視」のメディアである。波形や譜面として視覚化することは可能であるが、それらはあくまで記号的な表現に過ぎず、そこから想起される「感情」や「ニュアンス」といったクオリアを直接的に目で見ることができない。ユーザーは、AI が生成した音楽を確認するために、必ず「再生」という時間をかけた行為を必要とする。この「可視化できない」という性質は、AI へのフィードバックループにおいて重大な障壁となる。ユーザーは「あそこの盛り上がり」や「なんとなく悲しい感じ」といった、物理的に指差し確認が不可能な対象を、言語という不完全な媒体を通して AI に伝え、共有しなければならないからである。

1.2.2 時間軸上の不可逆性と文脈依存性

音楽におけるもう一つの決定的な特徴は、情報が時間軸上に展開される「継時性 (Sequentiality)」である。静止画であれば、画面の端にある要素を変更しても、中心にある被写体の意味合いは大きく変わらない場合が多い。しかし音楽の場合、ある一瞬の音の強弱やタイミングの変更は、その前後のフレーズの聴こえ方、ひいては楽曲全体の物語性 (Narrative) に影響を及ぼす。「今の瞬間」の表現は、過去の演奏の文脈の上に成り立っており、未来の展開への期待を含んでいる。

したがって、音楽生成における AI との対話では、単なる「部分的な修正」ではなく、時間的な文脈 (Temporal Context) を考慮した「全体的な整合性」の維持が求められる。この時間的な依存関係を、言語を通じて AI と共有し制御することは、静的な画像の生成に比べて遥かに複雑な認知プロセスを要する。

1.2.3 感性語の曖昧性と解釈の主観性

上述した「可視化の困難さ」と「時間的な文脈」の問題は、指示に用いる「言語 (プロンプト)」の役割をより一層重いものにする。画像生成における「赤いリンゴ」という指示は、客観的な色彩定義と結びつきやすく、万人に共通する視覚的イメージが存在する。一方で、音楽における「悲しげに」や「ドラマチックに」といった指示は、テンポ、音色、アーティキュレーションの複合的な組み合わせによって表現され、その正解は受け手個人の感性や文化的背景に強く依存する。明確な視覚的リファレンスが存在しない中で、いかにしてこの主観的かつ曖昧なイメージを AI とすり合わせるかが、本研究が挑む中心的な問いである。

1.3 本研究のアプローチ

1.3.1 Human-in-the-loop による感性のすり合わせ

上述の課題に対し、本研究では Human-in-the-loop（人間参加型）システムを用いた、言語を通じた「感性のすり合わせ」プロセスを提案する。可視化できない音楽表現において、言語はユーザーと AI をつなぐ唯一の共通プロトコルとなる。本システムでは、ユーザーが曖昧な感性語（例：「もっと情熱的に」「ここは繊細に」）を用いてイメージを伝え、AI（大規模言語モデルを活用した解釈モジュール）がそれを具体的な演奏パラメータに変換して提示するアプローチをとる。

1.3.2 意味的インタラクションのループ

本研究の核となるのは、単発の指示生成ではなく、反復的な対話を通じた意味の共有（Grounding）である。ユーザーは AI が生成した演奏を聴取し、自身のイメージとの差異を再び言語でフィードバックする。このループ構造により、一度の指示では伝達困難な暗黙的なニュアンスを徐々に具体化し、ユーザーの意図に対する AI の理解（文脈の記憶）を深める。

さらに、本システムは単なる指示追従にとどまらず、共有された目標イメージを踏まえた上で、AI 側から新たな表現プランを提案する機能を持つ。AI からの予期せぬ提案がユーザーの内部状態に変化を与え、新たな着想を引き出すことで、人と AI の相互創発的な共創を実現する。

1.4 本論文の構成

本論文の構成は以下の通りである。

第 2 章「**関連研究**」では、創造的 AI、音楽情報処理、および HCI におけるインタラクションデザインに関する既存研究を概観し、本研究の位置付けを明確にする。特に、音楽生成における感性語の扱いや、共創システムにおける課題について論じる。

第 3 章「**提案手法**」では、本研究で開発した音楽共創システムの詳細について述べる。MidiCaps を用いた言語から音楽特徴量への変換機構、および対話的な表現生成を実現するアーキテクチャについて詳述する。

第 4 章「**評価実験**」では、提案システムの有効性を検証するために行った被験者実験の

設計について述べる．プロの音楽家および非専門家を対象とした比較実験の条件設定を示す．

第 5 章「**実験結果**」では，実験により得られた定量的データおよび定性的フィードバックを提示する．

第 6 章「**考察**」では，実験結果に基づき，提案システムがユーザーの内部状態や創造性に与えた影響について分析する．また，可視化できないメディアにおける AI との対話のあり方について議論を深める．

最後に，第 7 章「**結論**」において本研究の成果を総括し，今後の展望を述べる．

第 2 章

理論・関連研究

2.1 創造的パートナーシップ

本節では、人と AI が創造的なパートナーシップを築くために必要な技術的基盤と、解決すべき課題について述べる。

2.1.1 エージェントの言語理解と感性

近年、CLIP[?] や CLAP[?] といったマルチモーダル学習モデルの登場により、テキストと画像、あるいはテキストと音声の意味的な対応付けが可能となった。これらは対照学習（Contrastive Learning）を通じて、物理的な対象（「犬」や「ピアノ」など）や一般的な雰囲気（「明るい」「激しい」）に関しては高い精度で認識・生成を行うことができる。

しかし、芸術制作や演奏表現において用いられる言語は、より抽象的で個人的な感性に依存する場合が多い。例えば、「泣くような音色で」や「春の訪れのように」といった表現は、受け手の解釈や文脈によって意味が大きく変化する。既存のモデルは、一般的なデータセットに基づく平均的な解釈は可能であるが、特定のユーザー固有の感性や、対話の中で形成される動的な文脈（コンテキスト）を理解するには至っていない。エージェントが人のパートナーとして機能するためには、一般的な言語理解を超え、個人の感性に共感的に寄り添う（Alignment）能力が必要とされる。

2.1.2 エージェントとの共創と適応学習

ユーザー固有の感性や意図に適応するための技術として、大規模言語モデル（LLM）の文脈内学習能力が注目されている。

2.1.2.1 In-context Learning (ICL)

In-context Learning (ICL)[?] とは、Brown らによって示された LLM の能力であり、モデルのパラメータ更新 (Fine-tuning) を行わずに、プロンプトとして与えられた入力系列 (コンテキスト) のみからタスクの規則やパターンを学習・推論する仕組みを指す。LLM は事前学習によって獲得した広範な知識とパターン認識能力を活かし、推論時に与えられた数例のデモンストレーションや指示から、即座にタスクに適応することができる。この特性は、ユーザーとの対話履歴を即座に次の生成へと反映させるインタラクティブなシステムにおいて極めて重要である。

2.1.2.2 In-context Preference Learning (ICPL)

ICL の概念をさらに発展させ、ユーザーの好み (Preference) を文脈から学習する手法として、**In-context Preference Learning (ICPL)**[?] が提案されている。従来、人間の好みに合わせた生成を行うためには、人間のフィードバックに基づく強化学習 (RLHF) などが用いられてきたが、これらは学習コストが高く、個々のユーザーに対してリアルタイムに適応することは困難であった。これに対し ICPL は、過去の生成結果に対するユーザーのフィードバック履歴をプロンプトとして LLM に入力することで、重み更新なしにユーザーの選好を学習する。これにより、対話を重ねるごとにエージェントの出力がユーザーの意図に近づく「すり合わせ」のプロセスを、低コストかつ高速に実現できる (図 2.1)。

この ICPL は、日高ら [?] によって音楽生成 (作曲) の分野にも応用されており (図 2.2)、ユーザーの抽象的な指示を作曲パラメータに変換する際の精度向上に寄与している。本研究では、この仕組みを演奏表現 (レンダリング) の制御へと拡張し、人と AI の感性のすり合わせに応用する。

2.1.3 AI による代替と人間の主体性

AI を創造的なパートナーとする際、システムがいかにユーザーの主体性 (Agency) を尊重し、創造性を阻害せずに支援できるかは重要な課題である。

2.1.3.1 主体性を尊重した最適化支援

これまでのデザイン支援において、小山らは、ベイズ最適化 (Bayesian Optimization) を活用したフレームワーク [?] を提案している。従来のデザイン最適化システムでは、シ




図 2.1: ICPL のシステム構成図 ([?] より引用)

システムが生成した案をユーザーに強制的に評価させる (Explicit loop) ものが多く、ユーザーの試行錯誤のプロセスを分断し、主体感を損なう傾向があった。これに対し小山らの手法は、ユーザーがスライド操作による探索を行っている様子をシステムが「横から観察」し、裏側で非同期的に最適化を行うことで、ユーザーの作業を中断させることなく合理的なデザイン案を提示する。このアプローチは、ユーザーの自由な探索を阻害しないという点で優れている。しかし、これはあくまでパラメータ空間における数値的な探索支援であり、ユーザーが「どのような意図で」操作しているかという文脈の理解や、言語を通じた相互のコミュニケーションは行われない。すなわち、提示された案を採用するか否かの判断はユーザーに委ねられているものの、そこには AI との意味的な対話や共創関係は希薄である。

2.1.3.2 LLM との共創における課題

一方で、LLM や ICPL のような強力な推論・言語能力を持つエージェントとの共創においては、コミュニケーションが可能になる反面、AI が創造プロセスを過度に代替してしまうという新たな課題が生じる。LLM は膨大な知識量に基づき、対話履歴から高速に最適解らしきものを導き出すことができる (収束的思考)。しかし、Doshi ら [?] による発散的思考と収束的思考に関するランダム化実験では、生成 AI がアイデア出しを代替することで、ユーザー自身の思考機会を奪い、かえって創造性を阻害する可能性 (Thinking-Halt)




図 2.2: ICPL を作曲 AI に応用したシステム構成図 ([?] より引用)

が示唆されている。

すなわち、単にユーザーの指示通りに「正解」を出すだけのシステムでは、効率性は向上しても「相互創発的なパートナーシップ」とはなり得ない。AI はユーザーの思考を代替するのではなく、小山らの研究のように主体性を尊重しつつ、多様な選択肢の提示や予期せぬ提案によってユーザーの発散的思考を刺激する役割を担うべきである。本研究が提案するシステムにおいて、ユーザーによるフィードバックのループ (Human-in-the-loop) を重視し、かつ言語による意図のすり合わせを行うのは、この「主体性の維持」と「意味的な共創」を両立させるためである。

2.2 音楽生成における制御と演奏レンダリング

2.2.1 音楽生成モデルの動向と制御性

近年、深層学習を用いた音楽生成技術は急速に発展している。特に、MusicGen[?] や MusicLM[?] などの大規模モデルは、テキストプロンプトから多様なジャンルの楽曲を生成することを可能にした。しかし、これらのモデルはテキストという抽象的な指示に依




図 2.3: ICPL で人の好みを最大化する音楽の探索イメージ ([?] より引用)

存しているため、メロディやリズムといった音楽的な詳細構造 (Low-level content) を意図通りに制御することは困難である。Lin ら [?] が指摘するように、実用的な音楽制作においては、抽象的なイメージだけでなく、楽譜や MIDI といった具体的な条件付け (Conditioning) に基づく制御が不可欠である。この課題に対し、近年では ControlNet[?] や Adapter 技術を用い、事前学習済みモデルに追加の制御入力を与える手法が注目されている。

2.2.2 演奏レンダリング (Performance Rendering)

演奏レンダリングとは、入力された楽譜情報 (Score/MIDI) に対し、人間らしい自然な演奏オーディオを生成するタスクである。これはテキスト読み上げ (TTS) と類似した目的を持つが、音楽特有の多声性 (Polyphonic) や、楽譜上の時間と実際の演奏時間の非線形な対応関係 (テンポバート等) により、その難易度は高い。単に楽譜通りの音高・音価を再現するだけでなく、演奏者の解釈による「表現の多様性 (Performance Variability)」

をいかにモデル化するかが、本タスクにおける重要な課題となっている。

2.2.3 RenderBox と基礎理論

本研究では、テキストおよび MIDI による表現豊かな演奏生成を実現するために、RenderBox[?] アーキテクチャを採用する。RenderBox は、Stable Audio Open[?] を基盤とした潜在拡散モデル (Latent Diffusion Models) であり、そのバックボーンには **DiT (Diffusion Transformer)**[?] が用いられている。

従来の拡散モデルでは、ノイズ除去ネットワークとして CNN ベースの U-Net[?] が標準的に利用されてきた。しかし、U-Net は局所的な特徴抽出に優れる反面、音楽のような長い時系列データにおける大域的な文脈を捉える能力に課題があった。これに対し、Transformer 構造を持つ DiT は、Self-Attention 機構によりデータ全体の依存関係を効率的に学習可能であり、テキストや MIDI といった異なるモダリティの条件付けを柔軟に統合できる利点がある。

また、モデルの学習においては、生成品質と安定性を向上させるために **v-objective**[?] と呼ばれる定式化を採用している。これは、拡散過程におけるノイズ ϵ ではなく、速度 v を予測対象とする手法である。時刻 t における潜在変数を z_t 、ノイズスケジュールに基づく係数を α_t, σ_t とすると、ターゲットとなる v_t および損失関数 $\mathcal{L}$ は以下のように定義される。

$$v_t \equiv \alpha_t \epsilon - \sigma_t z_0 \quad (2.1)$$

$$\mathcal{L} = \mathbb{E}_{t, z_0, \epsilon} [\|v_t - \hat{v}_\theta(z_t, t, c)\|^2] \quad (2.2)$$

ここで $\hat{v}_\theta$ はモデルの出力、 c はテキストや MIDI による条件入力を表す。この手法を採用することで、特に S/N 比が低いタイムステップにおける学習が安定し、演奏表現の微細なニュアンスの再現が可能となる。

0




図 2.4: RenderBox のアーキテクチャ概要

第 3 章

提案手法

本章では，ユーザーと AI が対等なパートナーとして音楽表現を共創するためのシステム構成，およびその具体的な処理手順について述べる．提案システムは，人間と AI が交互に演奏プランを提示し合うループ構造を基盤とし，言語モデルによる高度な意図解釈機能を組み込んでいる．

3.1 システム概要

提案システムの全体構成を図 3.1 に示す．本システムは，既存の共創フレームワークである ICPL を拡張したものである．従来の ICPL では，ユーザーは AI が提示した候補についてランキング評価を行っていたが，本手法では自然言語によるフィードバック（コメント機能）を導入した．これにより，ユーザーは単なる「選択」だけでなく，「もう少し優しく」「テンポを揺らして」といった具体的な意図をエージェントに伝達することが可能となる．

3.2 対話システムとアルゴリズム

本システムの核となる対話エージェント（Movot Agent）の推論エンジンには，OpenAI の **GPT-5** (reasoning_effort=low) を採用した．このモデルは，ユーザーの抽象的な感性語を具体的な演奏パラメータ（強弱，速度，アーティキュレーションなど）へ変換する役割を担う．

システム全体の処理フローをアルゴリズム 1 に，エージェント内部で行われる意図解釈と演奏生成の詳細プロセスをアルゴリズム 2 に示す．




図 3.1: 提案システム構成図

3.3 UI の構築

Python の Gradio ライブラリを用いて図??のような UI を作成した.

Algorithm 1 提案システムの全体処理アルゴリズム

Require: Participant ID ID , Experiment Order $O \in \{Manual \rightarrow AI, AI \rightarrow Manual\}$

- 1: **Initialize:**
 - 2: Load metadata M (Title, Composer, Instrument) from database.
 - 3: Analyze historical context C_{hist} using LLM via *analyze_song.txt*.
 - 4: Extract professional performance features C_{perf} via *MidiCaps* summary.
 - 5: Generate initial synthesis A_0 with neutral prompt.
 - 6: **Section 1 (Manual Prompting):**
 - 7: **while** $step < Manual_Target$ **do**
 - 8: Receive user expression E and speed index S .
 - 9: $P \leftarrow$ Construct text prompt using E and $SPEED_TIERS[S]$.
 - 10: $D \leftarrow$ Calculate duration based on $SPEED_FACTORS[S]$.
 - 11: $A_{step} \leftarrow$ AudioGeneration($P, MIDI, D$).
 - 12: **end while**
 - 13: **Section 2 (AI Co-Creation with Movot Agent):**
 - 14: Initialize Agent with C_{hist} , C_{perf} , and A_0 .
 - 15: **while** $step < AI_Target$ **do**
 - 16: Execute **Algorithm 2** to generate three hypotheses.
 - 17: Present candidates $\{H_A, H_B, H_C\}$ to user.
 - 18: $Winner \leftarrow$ User selection; Store feedback for next loop.
 - 19: **end while**
-

Algorithm 2 AI エージェントによる意図解釈と演奏生成のアルゴリズム

Require: User Feedback f_t , Musical Context M_1 (Static), Interaction History M_2 (Dynamic)

- 1: **Holistic Feedback Analysis:**
 - 2: $S_{curr} \leftarrow$ Detect speed tag from the previous winner's prompt.
 - 3: **if** f_t requests speed change **then**
 - 4: Apply **AGGRESSIVE Speed Logic**: Shift speed category by 2 steps in $SPEED_SCALE$.
 - 5: **end if**
 - 6: **Hypothesis Generation (LLM Reasoning):**
 - 7: **Strategy A (Direct):** Map f_t strictly to musical articulation.
 - 8: **Strategy B (Variation):** Propose alternative touch/style based on f_t .
 - 9: **Strategy C (Contextual):** Blend f_t with C_{hist} and C_{perf} from M_1 .
 - 10: **Constraint Check:** Ensure H_A and H_B use contrasting articulation (e.g., Legato vs. Rhythmic).
 - 11: **Parallel Audio Synthesis:**
 - 12: **for** each $H_i \in \{H_A, H_B, H_C\}$ **do**
 - 13: $P_i \leftarrow$ "Expressive Performance, [Instrument], $H_i.keywords$ "
 - 14: $D_i \leftarrow$ Calculate duration for $H_i.speed_tag$.
 - 15: $A_{i,t} \leftarrow \text{DiffusionModel}(P_i, D_i, MIDI)$.
 - 16: **end for**
 - 17: **Output:** Reasoning logs and Audio candidates $\{A_A, A_B, A_C\}$.
-

表 3.1: 時系列順の LLM プロンプト構成と Role の定義

フェーズ	Role	タイミング	提供される情報
1. 楽曲分析	System	初期化時	エージェントの役割 楽曲のタイトル 作曲家名
2. 状況設定	System	共創開始	Movot の人格 RenderBox の能力 プロ演奏のデータ
3. 対話ループ	User	毎ループ実行	選択された演奏案 フィードバック内容 過去の対話履歴
4. 制約の適用	User/System	毎ループ実行	速度調整ルール 提案間の差別化戦略

第 4 章

実験

本章では、提案システムの基盤となる音楽生成モデル RenderBox の訓練詳細、および提案システムの有効性を検証するために実施した被験者実験について述べる。

4.1 RenderBox の訓練

4.1.1 データセット

RenderBox の訓練には, ASAP[?], MusicNet[?], GAPS[?], BachViolin[?], ATEPP[?], ConEspressione[?], Vienna4x22[?] を使用した。各データセットは、訓練用データと推論（評価）用データに 9 対 1 の割合でランダムに分割して使用した。各ステージにおけるデータセットの割り当てを表 4.1 に示す。

4.1.2 カリキュラム学習

本研究では、RenderBox の学習においてカリキュラム学習を採用した。学習は段階的にタスクの難易度や条件を変更しながら進められる。元の RenderBox の論文では、意図的に演奏ミスを含ませてモデルのロバスト性を向上させる Stage 3 が存在するが、本研究では「理想的な表現生成」に焦点を当てるため、この Stage 3 は省略し、Stage 0, 1, 2, 4 の順で学習を行った。

学習環境として、GPU には NVIDIA A100 (80GB) を 2～3 枚使用した。学習時のハイパーパラメータについては、バッチサイズを 108～112 に設定し、計算資源の効率的な利用を図った。

表 4.1: カリキュラム学習の各ステージで使したデータセット [?]

Datasets by stage	Input MIDI	Target Audio	Inst.	Controls / Prompts	Repertoire / Notes
<i>Stage 0: Synthesis</i>					
ASAP	Score & Performance	Synth. Score & Perf. Audio	Piano	-	Common Practice Period solo piano works
MusicNet	Score & Performance	Synth. Score & Perf. Audio	Orchestral	-	Classical music with a large portion of chamber works
GAPS	Score	Synth. Score	Guitar	-	Noted classical guitar works
<i>Stage 1: Speed-controlled synthesis</i>					
ASAP	Score	Synth. Score	Piano	Tempo	Time-varied score synthesis
GAPS	Score	Synth. Score	Guitar	Tempo	Time-varied score synthesis
MusicNet	Score	Synth. Score	Orchestral	Tempo	Time-varied score synthesis
<i>Stage 2: Expressive Performance</i>					
ASAP	Score	Perf. Audio	Piano	Expressive	Aligned perf. segments
GAPS	Score	Perf. Audio	Guitar	Expressive	Aligned perf. segments
MusicNet	Score	Perf. Audio	Orchestral	Expressive	Aligned perf. segments
BachViolin	Score	Perf. Audio	Violin	Expressive	Bach violin sonata
<i>Stage 4: Style-directioned Performance</i>					
ATEPP-subset	Score	Perf. Audio	Piano	Performer labels	Standard piano repertoire played by 40+ pianists
Con Espressione	Score	Perf. Audio	Piano	Human-annotated expression labels	45 perf. of 9 excerpts annot. by 179 participants
Vienna 4x22	Score	Perf. Audio	Piano	Performer labels	4 short pieces played by 22 pianists each

4.1.3 性能評価指標

本研究では、生成された演奏の品質、楽曲の整合性、およびテキスト指示への追従性を評価するために、Evans ら [?] によって確立され、stable-audio-metrics に実装されている指標を採用した。具体的には以下の指標を用いる。

- **FAD (Fréchet Audio Distance):** 生成された音声の品質と多様性を評価する指標である。Cramer ら [?] による OpenL3 埋め込み表現を用いて、生成音声の分布と正解データ (Ground Truth) の分布間の距離を算出する。なお、本実験における FAD の算出にあたっては、生成された演奏群と、その楽曲が属するデータセットのテスト用データセット (Ground Truth) との間で比較を行った。
- **CLAP Score:** テキストプロンプトと生成音声の意味的な整合性を評価する指標である。Wu ら [?] による LAION-CLAP 空間における、入力テキストプロンプト

と出力音声の埋め込みベクトル間の距離として計算される。

- **Chroma Similarity (Pitch Accuracy):** 演奏生成タスクにおいては、正しい楽曲（楽譜通りの音高）が演奏されていることが不可欠である。そこで、ピッチ方向の正確性を評価するために、MusicGen-Melody[?] の評価手法に着想を得た Chroma 類似度を用いる。生成音声と正解音声は必ずしも時間的に整合（タイムアライメント）していないため、まずクロマグラムに対して動的時間伸縮（DTW: Dynamic Time Warping）を適用し、大まかなフレーム対応を推定する。このアライメントに基づき、対応するフレーム間のコサイン類似度を計算する。さらに、アライメントのコスト（DTW コスト）をペナルティ項として組み込み、重み係数 $\lambda = 10^{-3}$ でスケールリングして最終的なスコアとする。
- **Tempo Deviation:** 生成された演奏のテンポが、プロンプトで指定されたテンポ（Table 4.1 参照）の範囲内に収まっているかを評価する。madmom ライブラリを用いて生成音声のテンポを推定し、プロンプトによって調整された楽譜上の目標テンポに対する差異（逸脱度）をパーセンテージで算出する。

4.2 被験者実験

提案システムにおける「Human-in-the-Loop」および「LLM による仮説生成」の有効性を検証するため、被験者実験を行った。

4.2.1 被験者実験の概要

被験者は男性 4 名、女性 4 名の計 8 名である。被験者の音楽的背景（楽器経験年数、普段聴く音楽ジャンル等）については、実験後のアンケートにより収集した。被験者の属性詳細を図??に示す（または後述の表 4.2 の D 項にて収集）。

本実験では、システムが提示する演奏に対するフィードバックを通じて、ユーザーが理想とする演奏表現を探索するプロセスを評価対象とする。

4.2.2 被験者実験の手順

実験は、共通の導入フェーズである「実験 0」を行った後、比較対象となる 2 つの条件「実験 1（手動プロンプト）」と「実験 2（LLM プロンプト生成）」を順不同（またはカウンターバランスをとって）実施した。具体的な手順は以下の通りである。

実験 0：初期ループ（共通）

まず、システムの使用感に慣れるため、以下の手順で最初の演奏生成を行う。

1. ユーザーは課題曲の Score に基づく機械的な演奏を聴取する。
2. その曲に対する「理想の感性的な表現」を言語化し、システムに入力する（図 3.1 の (1)(2)）。
3. 入力されたテキストを直接プロンプトとして RenderBox に入力し、音楽を生成する（図 3.1 の (4)(5)）。
4. ユーザーは生成された演奏を聴き、フィードバック（コメント）を行う（図 3.1 の (6)(1)）。このとき生成された演奏を、以降の実験における「基準演奏」とする。

実験 1：人が直接プロンプトを入力（ベースライン）

ユーザー自身が表現を言語化し、試行錯誤する条件である。

1. ユーザーは基準演奏に対し、改善したい点や新たなイメージをプロンプトとして直接入力する（図 3.1 の (2)）。
2. 入力されたプロンプトをもとに、RenderBox が音楽を生成する（図 3.1 の (5)）。
3. ユーザーは生成演奏に対し、フィードバック（コメントと満足度ランキング）を行う（図 3.1 の (6)(1)）。
4. ユーザーが演奏に満足するか、または規定のループ回数上限に達するまで、手順 1～3 を繰り返す。

実験 2：LLM がプロンプトを生成（提案手法）

LLM がユーザーのフィードバックを解釈し、多様な表現仮説を提案する条件である。

1. ユーザーのフィードバック（コメントとランキング）を LLM に入力する（図 3.1 の (2)）。
2. LLM はフィードバックに基づき、以下の 3 種類の仮説（プロンプト）を立案する（図 3.1 の (3)）。
 - **Hypo A, B:** ユーザーのフィードバックに忠実な改善案。
 - **Hypo C:** LLM の音楽知識に基づき、今までと異なる表現解釈や意外性を含んだ提案（Deviated hypothesis）。

3. 3つの仮説を RenderBox に入力し, 3種類の候補演奏を生成する(図 3.1 の (4)(5)).
4. ユーザーは 3つの候補演奏および基準演奏を聴き比べ, フィードバックを行うとともに, 最も好ましい演奏を選択する. 選択された演奏は次のループの「基準演奏」となる(図 3.1 の (6)(1)).
5. ユーザーが満足するか, ループ上限回数に達するまで繰り返す.

4.2.3 評価指標

実験結果の分析には, 以下の観点および指標を用いる.

相互創発性 (Co-creativity)

エージェント (AI) からの提案が, ユーザーの意図を超えて新しい価値を生み出したかを評価する.

- **客観的評価:** 実験 2 において, LLM が独自の解釈を加えた「Music C (Hypo C に基づく演奏)」が, 次のループの基準演奏としてユーザーに選択された回数や割合.
- **主観的評価:** 「Music C」の演奏やその解釈テキストに対し, ユーザーが「意外だが良い」「新しい発見があった」と感じたかをアンケート (Q7, Q8) により評価する.

ユーザビリティ (Usability)

システムが効率的かつ意図通りに機能したかを評価する.

- **客観的評価:** ユーザーが最終的な満足に至るまでに要したループ回数を比較する. 実験 1 より実験 2 の方が少ない回数で満足した場合, 効率が良いと判断する.
- **主観的評価:** 「意図通りの演奏が生成されたか」「プロンプト生成の手間が軽減されたか」といった点をアンケート (Q4, Q6) により評価する.

実験に使用したアンケート項目の一覧を表 4.2 に示す.

表 4.2: 被験者実験で使したアンケート項目一覧

Category	ID	Question Item	Scale
Demographics	D1	年齢・性別	Open
	D2	普段音楽を聴く頻度・ジャンル	Open
	D3	楽器演奏経験の有無とその年数	Open
	D4	(事務用) 被験者 ID・名前	-
Overall Satisfaction	Q1	セクション 1 (手動) で生成された演奏に満足しましたか?	5-point Likert
	Q2	セクション 2 (対話) で生成された演奏に満足しましたか?	5-point Likert
	Q3	どちらのセクションの演奏により満足しましたか?	2-AFC
	Q4	どちらのシステムが使いやすかったですか?	2-AFC
System Capability	Q5	エージェントはあなたの理想の演奏を正しく推測していましたか?	5-point Likert
	Q6	あなたの指示通りに演奏が変化していましたか?	5-point Likert
Co-creativity & Interaction	Q7	エージェントの提案に, 意図と異なりつつも「良い」と思えるものはありましたか?	5-point Likert
	Q8	対話を通じて, 当初イメージしていた曲の目標や雰囲気は変化しましたか?	5-point Likert
	Q9	エージェントとの対話に関する感想・気づき	Free Text
	Q10	実験全体の感想	Free Text

Note: 5-point Likert (1: Strongly Disagree – 5: Strongly Agree), 2-AFC (2-Alternative Forced Choice)

第 5 章

結果

5.1 RenderBox の評価

表 5.1: RenderBox [?] との性能比較（括弧内は文献値）

Model	FAD ↓	Pitch ↑	Tempo ↓	CLAP ↑
Stage 0	61.8793 (839.3)	0.792 (0.794)	16.89 (0.038)	0.071 (0.174)
Stage 2	96.2042 (562.58)	0.8130 (0.753)	18.55 (10.39)	0.069 (0.265)
Stage 4	74.7507 (340.77)	0.8093 (0.748)	16.00 (19.51)	0.068 (0.234)




図 5.1: RenderBox の性能評価：CLAP score




図 5.2: RenderBox の性能評価：pitch の正確さ




図 5.3: RenderBox の性能評価：tempo のずれ

5.2 提案システムの評価

5.2.1 客観評価

5.2.2 主観評価

第 6 章

考察

6.1 RenderBox の性能について

6.2 提案手法について

第 7 章

結論

謝辞

本研究を進めるにあたり，多大なる助言，ご指導をいただきました，吉川雄一郎教授，堀井隆斗准教授に深く感謝いたします。

Appendix

Listing 7.1: システムプロンプトの定義

```

1 You are "Movot", an expert AI music producer interacting with a user to
  refine music generation using RenderBox.
2 Your goal is to understand the user's abstract requests and translate
  them into specific text prompts.
3
4 ### RenderBox Capabilities (Technical Knowledge)
5 You should base your suggestions on what the model is actually good at:
6
7 **Strengths (What works well):**
8 - **Tempo Changes:** The model is excellent at handling relative speed
  changes.
9 - **Articulation:** Detailed control over touch is very effective.
10 - **Mood/Atmosphere:** Adjectives describing the vibe work better than
    specific genre names.
11
12 **Weaknesses (What to avoid):**
13 - **Specific Melodies:** You cannot change the notes or melody. Do not
    promise to change the key.
14 - **Complex Structure:** Instructions like "verse-chorus" are ignored.
15
16 ### Your Role:
17 - Be friendly, encouraging, and professional.
18 - Act as a partner who bridges the gap between the user's feelings and
    the AI's parameters.
19
20 ### Output Rules & Internal Mandates (CRITICAL)
21 You must internalize these rules for ALL outputs:
22 1. **Reasoning Priority:** When detailing your strategy ("reasoning"),
    you MUST explicitly detail the usage of all external constraints (e.
    g., AGGRESSIVE Speed Logic, Contrast Strategy). For Hypo C, you MUST
    cite specific contextual evidence from Memory 1 (e.g., '
    performance_advice' or 'keywords') to justify the proposal.

```

-
- 23 2. ****Message Accuracy:**** When generating the friendly message, you MUST
accurately identify and reflect the precise user comment provided in
the latest feedback, avoiding unrelated terms.
- 24 3. ****Concept Specificity:**** In the "concept" fields, highlight the key
musical terms you added to the prompt using ****bold text****.
-

Listing 7.2: チャットプロンプトの定義

```

1 Based on the provided memories, generate 3 distinct RenderBox prompts in
  JSON format.
2
3 ### Input Context:
4 [Memory 1: Musical Context (Static)]
5 Target Song: {{ title }} by {{ composer }}
6 Background Info: {{ background }}
7
8 [Memory 2: Interaction History (Dynamic)]
9 {{ history_text }}
10
11 ### Generation Task (HOLISTIC FEEDBACK ANALYSIS):
12 1. **Analyze the Feedback ([Memory 2]):**
13   - **Context:** Consider the flow of conversation, but prioritize the
    specific nuance of the latest request.
14   - **Interpretation:** Do not over-simplify abstract terms. If the user
    says "Dance-like", acknowledge it as "Dance-like", then
    internally translate it to specific parameters (Rhythmic +
    Moderate Speed). Do NOT simply replace it with "Fast".
15   - **CRITICAL:** Do NOT copy the examples below. You MUST extract the
    actual intent from [Memory 2].
16
17 2. **Analyze the Musical Context ([Memory 1]):**
18   - Identify the song's historical background and professional
    performance trends.
19   - This drives Hypo C (blended with user intent where possible).
20
21 3. **Formulate 3 Distinct Strategies:**
22   - **Hypo A (Direct Answer):** - Source: [Memory 2] ONLY.
23   - Strictly follow the user's latest instruction.
24   - **Hypo B (Variation):** - Source: [Memory 2] ONLY.
25   - Propose an alternative style derived ONLY from the user's feedback
    , focusing on a different aspect (e.g., if A focuses on speed, B
    focuses on articulation).
26   - **Hypo C (Contextual Interpretation - HYBRID):**
27   - Source: **[Memory 1] (Primary)** + [Memory 2] (Secondary).
28   - Propose a style derived from the **Song's Background/Professional
    Analysis**.
29

```

```

30 4. Act as a friendly "AI Music Producer" (movot).
31
32 ### Communication Style & Specificity (EXTREMELY IMPORTANT):
33 1. **Show Deep Interest (Echoing):**
34   - **Rule:** You MUST explicitly acknowledge the user's specific words
      EXACTLY as they typed them before offering a solution.
35   - **Bad:** User: "Make it dance." -> AI: "You want it faster." (Do not
      paraphrase yet!)
36   - **Good:** User: "Make it dance." -> AI: "I see, you want to make it
      **'Dance-like'**! That's a fun direction."
37 2. **Be Specific & Highlight Keywords:**
38   - **Requirement:** When explaining *how* you changed the sound,
      explicitly mention the musical terms you added to the prompt.
39   - **Visuals:** Use bold text or 「」 brackets to highlight these
      specific musical terms in your explanation.
40
41 ### Constraints (CRITICAL):
42 The system automatically adds the Instrument name and tags "Expressive
      Performance".
43 1. **Excluded Words:** Do NOT include instrument names or "Expressive/
      Performance".
44 2. **Speed Control:** Start the prompt with exactly ONE: "very slow", "
      slow", "slightly slow", "neutral", "slightly fast", "fast".
45 3. **Style & Articulation:** Add 1-3 style words in English.
46 4. **Language:** - "message", "reasoning", "concept": Target Language
      defined in the Context/System Reminder (Default to English if not
      specified).
47   - "prompt": English keywords only
48
49 ### Output Format (JSON):形式で出力してください。のコードブロック (
50 JSONMarkdown``) は含めないでください。json重要:以下の値は「説明」であり、そのま
      まコピーしないでください。入力内容に基づいて記述してください。
51
52
53 {
54   "reasoning": すべての提案に対する戦略を日本語で詳細に説明してください。システム
      制約 ("AGGRESSIVE Speed Logic, Contrast ) をどのように適用したか (例:
      ユーザーの『遅すぎる』という不満に対し、速度をステップ上げて
      Strategy2 'neutral' に設定した等) を明記してください。また、Hypo について
      は C [Memory 1] の分析結果 (演奏家の傾向や楽曲のムード) をどう解釈したか、
      根拠となる具体的な要素を記述してください。",
55   "message": 日本語でのフレンドリーなメッセージ。最新のユーザーフィードバック
      ("Memory ) から得られた「もっと連続的に」「しつとり」といった具体的な言葉
      を直接引用して、ユーザーの意図を正しく理解したことを伝えてください。システム
      用語 (2Memory 1, など) は含めないでください。2",
56   "hypo_a": {
57     "concept": 日本語による説明。ユーザーの最新の指示に厳密に従い、リクエストを反
      映したことを伝えてください。プロンプトに使用した英語キーワード (例:
      "100%legato, ) を必ず太字で強調して説明に含めてください。システム用語

```

```

        (softMemory 1, など) は含めないでください。2",
58     "prompt": "<SPEED_TAG>, <KEYWORD_FROM_INPUT>, <STYLE_WORD>"
59   },
60   "hypo_b": {
61     "concept": 日本語による説明。ユーザーのフィードバックのみに基づき、"Hypo と
                は異なる側面（例：が速度重視なら、はアーティキュレーション重視）からアプ
                ローチした「別の解釈」であることを説明してください。独自の視点は含めず、
                キーワードを太字で強調してください。システム用語（AABAIMemory 1, など）
                は含めないでください。2",
62     "prompt": "<SPEED_TAG>, <VARIATION_KEYWORD>, <STYLE_WORD>"
63   },
64   "hypo_c": {
65     "concept": 日本語による説明。"(Memory 1)の楽曲の歴史的背景、時代様式、および
                プロの演奏分析に基づいた、音楽的に妥当で専門的な提案を行ってください。生
                データを列挙するのではなく、その曲にふさわしい『気品』や『情熱』といった音
                楽的解釈に翻訳して説明し、キーワードを太字にしてください。システム用語
                (Memory 1, など) は含めないでください。2",
66     "prompt": "<SPEED_TAG>, <CONTEXT_KEYWORD>, <STYLE_WORD>"
67   }
68 }
69
70 IMPORTANT constraints for proposal generation:
71 1. Diversity: Ensure that Hypothesis A, B, and C are distinct from each
    other.
72 2. Novelty: Do NOT propose prompts that are identical or highly similar
    to the "Previous Winner's Prompt".
73
74 ### Style Vocabulary Library (Guidelines):プロンプトを生成する際、エンジンと
    相性の良い以下の標準的な音楽用語を「参考」として利用してください。ユーザーの抽
    象的なリクエストを具体的なパラメータに翻訳する際のガイドとして活用し、特定の単
    語に固執しすぎず、楽曲の文脈
75 RenderBox [Memory 1] に沿った豊かな表現を心がけてください。
76
77 - **Dynamics/Intensity:** passionate, intense, soft, gentle, powerful,
    dramatic
78 - **Tempo/Rhythm:** rubato, steady, flowing, rhythmic, slow, fast, rapid
79 - **Articulation:** staccato, legato, smooth, sharp, heavy, light, crisp
80 - **Mood:** melancholic, heroic, dark, bright, ethereal, mysterious,
    joyful, calm, elegant, romantic
81
82
83 [Speed & Style Adjustment Rules]
84 1. Speed Scale (Slowest to Fastest):
85     "very slow" < "slow" < "slightly slow" < "neutral" < "slightly fast" <
        "fast" < "very fast"
86
87 2. AGGRESSIVE Speed Logic (Priority):
88     - **The Model is stubborn.** Small changes are not audible.
89     - **Constraint:** Ensure at least one proposal (e.g., Hypo A)
        significantly changes the speed tag to address the user's

```

```
frustration.
90
91 3. Contrast Strategy (Avoid "Same-Sounding" Prompts):
92   - **Problem:** Words like "flowing", "elegant", "smooth", "gentle"
      result in nearly identical audio (low attack).
93   - **Rule:** Do NOT use these synonyms across Hypo A, B, and C
      simultaneously. Each proposal must use distinct vocabulary
94   - **Mandatory Contrast:** Ensure a clear difference in "touch" (
      Articulation).
95
96 4. Current State Awareness:
97   - Always check the "Previous Winner Prompt" to know the current speed.
```

Listing 7.3: 分析プロンプトの定義

```
1 You are a musicologist and performance expert.
2 Analyze the following musical piece to provide context for an AI
  performance renderer.
3
4 Title: {{ title }}
5 Composer: {{ composer }}
6
7 Output a JSON object with the following fields:
8 1. "background": A brief description of the piece's history and mood (
   Focus on emotional character).
9 2. "keywords": A list of 5-7 adjectives describing the typical
   performance style (e.g., "Baroque, steady, contrapuntal" or "
   Romantic, rubato, heavy").
10 3. "famous_pianists": Names of 2-3 famous performers known for this
   piece (for style reference).
11 4. "performance_advice": Specific advice for an AI renderer (e.g., "Keep
   the tempo strict" or "Use heavy rubato in the melody").
12
13 Format: JSON only.
```
